UNIVERSIDADE POLITÉCNICA DO CÁVADO E DO AVE

Licenciatura em Engenharia de Sistemas Informáticos

Integração de Sistemas de Informação · Trabalho Prático I

SISTEMA DE INTEGRAÇÃO E COMPARAÇÃO DE PREÇOS DE COMBUSTÍVEIS EM PORTUGAL

Relatório integrado das implementações em Pentaho Kettle e KNIME

Francisco Alberto Martins Campinho · N.º 31079 · Pentaho Kettle e Node-RED
Miguel Marques · N.º 33221 · KNIME
Docente: Óscar Ribeiro
Ano letivo 2026/2027

Outubro de 2026

Índice

Clique no título para abrir a respetiva secção (no Word, poderá ser necessário Ctrl + clique).

Resumo 3
1. Enquadramento 3
1.1. Contexto e organização da equipa 3
1.2. Motivação e relevância 4
2. Problema e objetivos 4
2.1. Descrição do problema comum 4
2.2. Objetivos e alcance 4
3. Estratégia e tecnologias 5
3.1. Organização geral da integração 5
3.2. Pentaho Kettle, KNIME e Node-RED 5
3.3. Fontes de dados e formatos 6
4. Transformações em Pentaho Kettle 7
4.1. Visão geral e ficheiros 7
4.2. Importação de Gasóleo e Gasolina 95 7
4.3. Integração, validação e duplicados 8
4.4. Consulta à GEO API PT 10
4.5. Cruzamento geográfico 11
4.6. Agregação e exportação CSV/XML 13
5. Workflow de integração em KNIME 16
5.1. Organização e extração de fontes 16
5.2. Preparação do CSV 17
5.3. Tratamento do JSON e das coordenadas 18
5.4. Joiner entre CSV e JSON 19
5.5. Integração do catálogo XML 20
5.6. Exportação e consulta do resultado 21
6. Jobs, execução e apresentação 22
6.1. Job principal no Kettle 22
6.2. Testes e histórico da execução 24
6.3. Node-RED e dashboard 24
7. Resultados e análise 27
7.1. Indicadores da implementação Kettle 27
7.2. Resultados da implementação KNIME 29
7.3. Leitura conjunta das duas abordagens 29
8. Validação, comparação e limitações 30
8.1. Verificações realizadas 30
8.2. Comparação técnica das ferramentas 30
8.3. Limitações e riscos 31
9. Vídeo de demonstração e repositórios 32
10. Conclusão e trabalhos futuros 32
11. Referências bibliográficas 33
Anexos 34

Resumo

Este relatório apresenta o desenvolvimento do Sistema de Integração e Comparação de Preços de Combustíveis em Portugal, realizado na unidade curricular de Integração de Sistemas de Informação. O projeto aborda um problema comum — a preparação e associação de dados heterogéneos relativos a combustíveis, postos e localização — através de duas implementações ETL distintas, desenvolvidas em Pentaho Data Integration (Kettle) e KNIME Analytics Platform.

Na solução Kettle, foram importados os dados de Gasóleo simples e Gasolina simples 95 da DGEG e associadas referências administrativas da GEO API PT. O tratamento foi repartido por oito transformações orquestradas num Job, com etapas de limpeza de preços, validação, controlo de duplicados, normalização geográfica, Stream Lookup e agregação. A execução documentada conserva 6.009 observações válidas e produz 555 grupos estatísticos, exportados para CSV e XML e consultados no Node-RED através de uma tabela, gráfico e endpoint HTTP.

A implementação KNIME integra uma fonte CSV de preços, um JSON geográfico e um catálogo XML de combustíveis. O workflow prepara tipos, valores em falta, duplicados, nomes de marcas e coordenadas, executa Joiner entre as fontes, associa os códigos do catálogo XML e escreve o resultado em CSV. A saída observada contém 5.466 linhas e foi consultada no Excel. Os valores de ambas as soluções descrevem saídas de natureza e granularidade diferentes, pelo que não demonstram equivalência de bases de dados nem comunicação automática entre as ferramentas.

Palavras-chave: integração de sistemas de informação; ETL; combustíveis; Pentaho Kettle; KNIME; Node-RED; CSV; JSON; XML.

1. Enquadramento

1.1. Contexto e organização da equipa

O trabalho foi realizado no âmbito de Integração de Sistemas de Informação, no ano letivo 2026/2027. Francisco Alberto Martins Campinho (n.º 31079) desenvolveu a solução Pentaho Kettle/Node-RED e Miguel Marques (n.º 33221) a solução KNIME. As duas implementações tratam o mesmo problema de integração de preços de combustíveis, mas foram executadas separadamente.

O enunciado do Trabalho Prático I permite que os elementos do grupo explorem plataformas distintas. Este relatório reúne o problema, a metodologia e a avaliação, identificando as operações efetivamente realizadas em cada ferramenta. Não existe ligação automática documentada entre os dois workflows.

1.2. Motivação e relevância

Os preços são disponibilizados por posto e combustível. Para permitir uma análise territorial é necessário converter os valores numéricos, harmonizar nomes de localidades e relacionar as observações com uma referência geográfica. Na solução KNIME acrescenta-se o cruzamento com atributos de postos provenientes de JSON e com um catálogo XML.

As saídas respondem a necessidades diferentes: o Kettle produz estatísticas por município e combustível; o KNIME produz uma tabela consolidada de registos associados. As diferenças de estrutura e de chaves de correspondência impedem considerar as duas saídas equivalentes.

2. Problema e objetivos

2.1. Descrição do problema comum

As fontes apresentam preços por posto, informação administrativa e atributos geográficos em formatos diferentes. Os preços podem estar representados como texto, nomes de municípios e marcas nem sempre coincidem e as coordenadas podem ter precisões distintas. O trabalho procura preparar os campos relevantes e associar as fontes com regras verificáveis.

No Kettle, a correspondência geográfica é realizada por distrito e município normalizados, recuperando o código INE. No KNIME, a associação CSV/JSON é preparada com marcas e coordenadas, sendo posteriormente acrescentado o catálogo XML de combustíveis. As junções não têm as mesmas chaves nem geram resultados com a mesma granularidade.

2.2. Objetivos e alcance

O objetivo geral é implementar e documentar processos ETL para integrar e consultar dados de combustíveis, explicando as regras aplicadas, as saídas e a validação possível em cada ferramenta.

- Importar e interpretar fontes com formatos e estruturas distintos (CSV, JSON e XML, consoante a implementação).
- Converter corretamente preços textuais para campos numéricos, mantendo os identificadores e os atributos relevantes.
- Tratar valores em falta, valores inválidos e registos repetidos com regras explícitas.
- Relacionar informação geográfica, administrativa e de combustíveis mediante critérios de correspondência verificáveis.
- Exportar o resultado num formato utilizável e confirmar a execução e a leitura das saídas.
- Apresentar e comparar as duas abordagens sem declarar integração automática entre elas nem equivalência não demonstrada.

2.3. Delimitação e questões de consulta

A análise considera Gasóleo simples e Gasolina simples 95. O Kettle permite consultar médias, mínimos, máximos e número de observações por município e combustível. O KNIME produz uma tabela filtrável por combustível e município e ordenável por preço no Excel. Não foram desenvolvidas consultas de preços em tempo real.

O projeto não inclui recolha agendada, histórico de preços ou persistência numa base de dados. No Kettle, a GEO API PT fornece efetivamente a referência municipal; no KNIME, a consulta pontual à mesma API foi apenas um teste e não alimentou a tabela final.

3. Estratégia e tecnologias

3.1. Organização geral da integração

As duas abordagens seguem as fases ETL de extração, transformação e exportação, mas cada uma processa as suas fontes e gera uma saída própria.

Tabela 1 — Estratégia geral das duas implementações

Dimensão	Pentaho Kettle / Node-RED	KNIME
Entradas	CSV Gasóleo simples e Gasolina 95; referência de municípios em JSON via GEO API PT.	CSV com preços; JSON ArcGIS/DGEG de postos; catálogo XML de combustíveis.
Preparação	Limpeza do símbolo euro; conversão; validação; deduplicação; normalização municipal.	Conversão textual/numérica; Missing Value; deduplicação; filtro de preços; normalização de marcas e coordenadas.
Integração	União dos dois combustíveis e Stream Lookup para obter Codigo_INE.	Joiner de CSV+JSON e Joiner interno com o catálogo XML.
Resultado	555 grupos de estatísticas em CSV e XML, depois consultados no Node-RED.	Tabela integrada exportada como resultado_final.csv e consultada no Excel.

3.2. Pentaho Kettle, KNIME e Node-RED

O Pentaho Data Integration, através do Spoon, foi utilizado para configurar transformações (.ktr) e um Job (.kjb). As transformações implementam operações como leitura de CSV, REST Client, JSON Input, Filter Rows, Unique Rows, Stream Lookup, Sort Rows, Group By e exportação CSV/XML. O Job coordena a ordem de execução e os percursos condicionais de sucesso e falha.

No KNIME, o processamento organiza-se em nós de leitura e transformação, JSON Path, Ungroup, XPath, Joiner, Column Filter e CSV Writer, associados num único workflow.

No KNIME não está documentado um Job independente, agendamento automático ou dashboard. O encadeamento é o dos nós do workflow.

O Node-RED é utilizado apenas após o Kettle: lê o CSV das estatísticas, publica um endpoint HTTP e apresenta uma tabela e um gráfico. Não recalcula as estatísticas nem recebe dados do KNIME.

3.3. Fontes de dados e formatos

Tabela 2 — Fontes documentadas na implementação KNIME

Fonte	Formato	Conteúdo e função
Ficheiro de preços	CSV	Registos com informação sobre postos, município, distrito, preço, marca, combustível, data de atualização e coordenadas, entre outros campos presentes na fonte.
Dados de postos de abastecimento	JSON	Atributos de entidades geográficas disponibilizados pelo serviço ArcGIS da DGEG, incluindo identificador, marca e coordenadas.
Catálogo de combustíveis	XML	Tabela de referência com código, nome e unidade de cada combustível, usada para complementar a informação final.

O portal Preços dos Combustíveis Online da Direção-Geral de Energia e Geologia (DGEG) foi utilizado como referência de preços. No Kettle, os ficheiros foram separados por tipo de combustível e posteriormente reunidos; no KNIME, o CSV de preços é tratado como uma das três fontes de entrada. Os relatórios não fornecem informação suficiente para provar que os ficheiros usados nas duas implementações são idênticos, da mesma data ou com a mesma seleção de postos. A informação proveniente da DGEG deve ser identificada com a data da recolha efetivamente utilizada; essa data não está confirmada nos materiais analisados.

A GEO API PT é utilizada no Kettle como fonte de uma tabela administrativa de 308 municípios com nomes de distrito, município e código INE, obtida em JSON. O serviço geográfico ArcGIS/DGEG referido no KNIME devolve atributos de postos, incluindo objectid, marca e coordenadas nlatitude e nlongitude; não corresponde à mesma tabela de 308 municípios.

O CSV representa registos tabulares; o JSON contém estruturas com atributos geográficos; e o XML é usado como catálogo no KNIME e como formato de exportação no Kettle. As duas utilizações de XML são independentes.

3.4. Regras gerais de preparação

No KNIME foram aplicados tratamento de valores em falta, conversão de tipos, filtragem de preços, remoção de duplicados, normalização das marcas, preparação das coordenadas e dois Joiner. As condições e os resultados documentados são apresentados na secção 5.

3.5. Formatos e contratos de saída

No Kettle, as estatísticas são escritas em CSV UTF-8 delimitado por ponto e vírgula e também em XML. O Node-RED lê o CSV final. O KNIME exporta resultado_final.csv através do CSV Writer. A configuração exata do delimitador KNIME deve ser confirmada no ficheiro final.

4. Transformações em Pentaho Kettle

4.1. Visão geral e ficheiros

A implementação Kettle está dividida em oito transformações, desde a preparação dos CSV até ao cálculo e exportação de estatísticas. Os ficheiros intermédios permitem conferir o resultado de cada etapa.

A Tabela 3 identifica as transformações. A numeração original foi mantida: na versão final não existe um ficheiro com prefixo 02.

Tabela 3 — Inventário das oito transformações Kettle

Ficheiro (.ktr)	Responsabilidade
01_gasoleo_simples	Importação e limpeza de Gasóleo
03_gasolina_95_simples	Importação e limpeza de Gasolina 95
04_integrar_combustiveis	Integração dos dois combustíveis
05_validar_combustiveis	Validação de preço
06_identificar_duplicados	Controlo de duplicados
07_geoapi_municipios	Consulta da API territorial
08_cruzar_combustiveis_municipios	Cruzamento com códigos INE
09_estatisticas_combustiveis	Agregações e exportações

4.2. Importação de Gasóleo e Gasolina 95

4.2.1. Transformação 01 — leitura e limpeza do Gasóleo

O ficheiro original de Gasóleo simples contém a identificação e localização dos postos e os respetivos preços. Como Preco surge com símbolo de euro e vírgula decimal, é necessário limpar o texto antes de o converter num campo numérico.

Após a leitura do ficheiro, foram utilizados os passos "Limpar Símbolo Euro" e "Remover Espaço Preço" para retirar o símbolo da moeda e os espaços desnecessários. De seguida, o passo "Converter Preço para Número" permitiu criar o campo Preco_Numerico, utilizado posteriormente nas validações e no cálculo das estatísticas.

Foram também ajustados os formatos dos campos numéricos. Os preços passaram a ser apresentados com três casas decimais nos ficheiros tratados, enquanto as coordenadas de

latitude e longitude foram configuradas com oito casas decimais. A codificação UTF-8 foi utilizada para preservar corretamente os caracteres dos nomes e das localidades.

Durante o desenvolvimento, foi utilizada a opção Preview do Spoon para verificar se os campos estavam a ser lidos corretamente e se a conversão dos preços produzia os valores esperados.

Por fim, os dados tratados foram exportados para o ficheiro gasoleo_simples_tratado.csv, que será utilizado na transformação responsável por integrar os dois combustíveis.



Figura 1 — Transformação 01: leitura, limpeza de euro e espaços, conversão do preço e exportação. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

4.2.2. Transformação 03 — leitura e limpeza da Gasolina 95

A transformação 03 é responsável pela importação e tratamento dos dados de Gasolina simples 95. O processo é semelhante ao utilizado para o Gasóleo simples, começando pela leitura do ficheiro CSV original.

Os passos «Limpar Símbolo Euro», «Remover Espaço Preço» e «Converter Preço para Número» tratam o campo Preco. O resultado fica com a mesma estrutura de campos do Gasóleo.

Após o tratamento, os dados são exportados para o ficheiro gasolina_95_simples_tratado.csv, mantendo a mesma estrutura de campos utilizada na transformação do Gasóleo simples. Desta forma, os dois ficheiros ficam preparados para serem integrados numa única transformação.



Figura 2 — Transformação 03: normalização e exportação do CSV de Gasolina simples 95. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

4.3. Integração, validação e duplicados

4.3.1. Transformação 04 — união dos combustíveis

Para isso, são lidos os dois ficheiros tratados anteriormente, gasoleo_simples_tratado.csv e gasolina_95_simples_tratado.csv. Os dados são enviados para o passo "Juntar Combustiveis", que reúne os registos dos dois combustíveis num único fluxo.

«Juntar Combustiveis» reúne as linhas dos dois CSV, preservando a coluna Combustivel. Não é uma junção por posto nem compara identificadores de estabelecimentos.

O resultado é exportado para o ficheiro combustiveis_integrados.csv, que será utilizado na transformação seguinte para validar os preços.

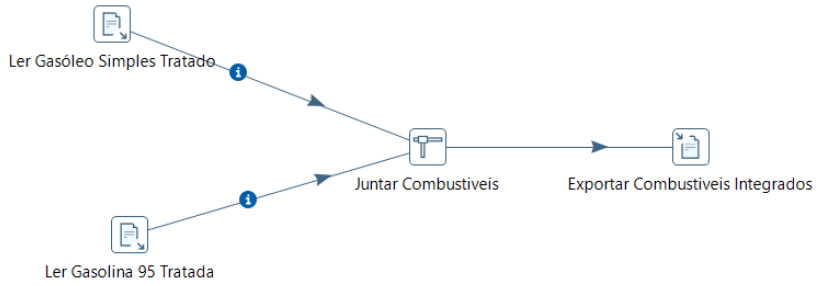


Figura 3 — Transformação 04: dois CSV tratados reunidos no fluxo Juntar Combustiveis. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

4.3.2. Transformação 05 — preço válido e inválido

A transformação 05 lê o ficheiro combustiveis_integrados.csv e utiliza o passo "Validar Preco", do tipo Filter Rows, para separar os registos aceites dos rejeitados.

Os registos considerados válidos são guardados no ficheiro combustiveis_validos.csv, enquanto os rejeitados são enviados para combustiveis_invalidos.csv. Esta separação permite identificar possíveis problemas nos dados sem os misturar com os registos que seguem para as próximas transformações.

Na execução final, foram validados 6.009 registos, não tendo sido identificado nenhum preço inválido. Assim, todos os registos passaram para a etapa seguinte, responsável pela identificação de duplicados.

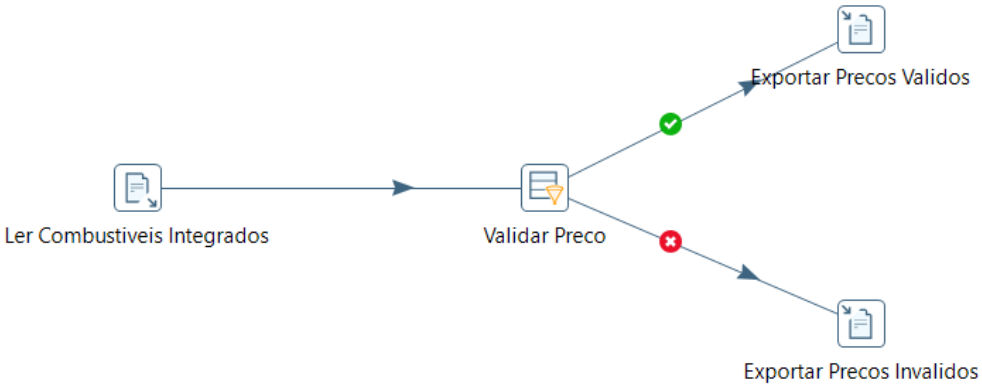


Figura 4 — Transformação 05: Filter Rows com saídas separadas para preços válidos e inválidos. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

A execução não encontrou preços inválidos. Este resultado confirma o comportamento do filtro nos dados testados, mas não substitui testes com preços incorretos introduzidos deliberadamente.

4.3.3. Transformação 06 — deteção de registos repetidos

O processo começa com a leitura do ficheiro combustiveis_validos.csv. De seguida, os registos são ordenados e enviados para o passo "Identificar Duplicados", que utiliza o operador Unique Rows para separar os registos únicos dos duplicados.

Os registos únicos são guardados num ficheiro que será utilizado na transformação seguinte, enquanto os duplicados são exportados separadamente para permitir a sua análise.

Na execução final, os 6.009 registos foram considerados únicos, não tendo sido identificados duplicados. Esta verificação permite evitar que registos repetidos, segundo os campos de comparação configurados, influenciem os cálculos estatísticos.

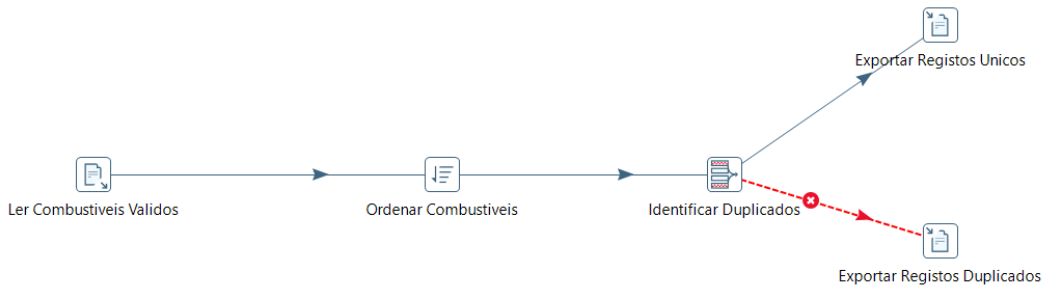


Figura 5 — Transformação 06: ordenação, Unique Rows e saídas de registos únicos e duplicados. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

O Unique Rows deteta repetidos segundo as colunas configuradas depois da ordenação. Não detetar duplicados nesta execução não exclui registos que representem o mesmo posto com valores diferentes.

4.4. Consulta à GEO API PT

A transformação 07 foi desenvolvida para obter informação sobre os municípios portugueses e os respetivos códigos INE, necessária para relacionar os dados dos combustíveis com uma referência geográfica.

Para isso, foi utilizada a GEO API PT, através de uma chamada HTTP realizada pelo passo REST Client do Pentaho.

A resposta da API é recebida em formato JSON e contém informação organizada por distritos e municípios. Como estes dados têm uma estrutura hierárquica, foram utilizados passos JSON Input para extrair os campos necessários.

Após o tratamento da resposta, foram selecionados os campos Distrito_API, Municipio_API e Codigo_INE, que serão utilizados na transformação seguinte para identificar os municípios presentes nos ficheiros de combustíveis.

Os códigos INE foram mantidos como texto para preservar possíveis zeros iniciais. Por exemplo, o código "0105" deve continuar a ser apresentado dessa forma, em vez de ser convertido para o número 105.

Na execução realizada, foram obtidos 308 municípios. Os dados foram exportados para o ficheiro municipios_api.csv, que serve de referência para o cruzamento geográfico.



Figura 6 — Transformação 07: REST Client, extração de JSON e catálogo de 308 municípios. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

O campo Codigo_INE necessita de tratamento distinto dos atributos numéricos. No exemplo fornecido no relatório, “0105” é um identificador e não uma quantidade; se fosse convertido em número, perder-se-ia o zero inicial. Esta preservação foi novamente verificada no XML final.

4.5. Cruzamento geográfico

4.5.1. Transformação 08 — chaves territoriais

A transformação 08 é responsável por relacionar os dados dos combustíveis com os municípios obtidos através da GEO API PT.

Inicialmente, são lidos os ficheiros combustiveis_sem_duplicados.csv e municipios_api.csv. Antes de realizar o cruzamento, foi necessário uniformizar os nomes dos municípios e distritos, removendo espaços desnecessários e convertendo os textos para maiúsculas.

Foi também corrigida uma diferença na escrita do município de Mêda. Nos dados utilizados, surgia a variante "MEDA", enquanto a referência geográfica apresentava "MÊDA". Para resolver esta situação, foi aplicada uma substituição através de uma expressão regular.

Depois desta preparação, os dados são enviados para o passo "Cruzar Combustiveis Municipios", responsável por associar os códigos INE aos registos dos combustíveis. De seguida, o passo "Validar Correspondencia GEO" separa os registos com correspondência dos restantes.

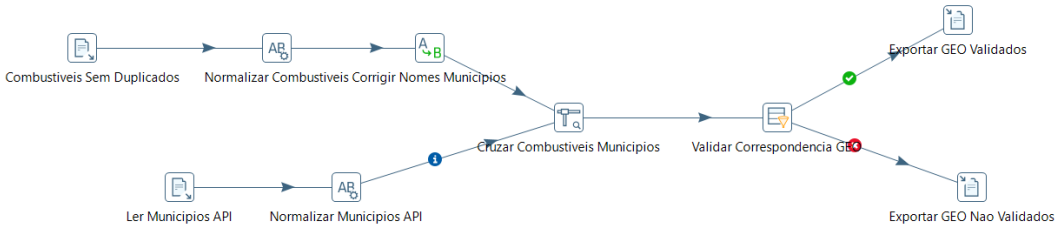


Figura 7 — Transformação 08: preparação das chaves e ligação entre observações e referência territorial. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

4.5.2. Stream Lookup e verificação da correspondência

O cruzamento é realizado através do operador Stream Lookup, que compara os nomes normalizados dos distritos e municípios dos dois ficheiros. Quando encontra uma correspondência, devolve o respetivo Codigo_INE, que é acrescentado ao registo do combustível.

O passo seguinte verifica se Codigo_INE não é nulo. Os registos com correspondência são guardados em combustiveis_geo_validados.csv, enquanto os restantes são enviados para combustiveis_geo_nao_validados.csv. O código INE foi mantido como texto para preservar os zeros iniciais, como acontece nos códigos 0102 e 0105.

Na execução final, os 6.009 registos foram associados com sucesso, não tendo sido identificados municípios sem correspondência. Este resultado foi confirmado através da pré-visualização dos dados e das métricas de execução.

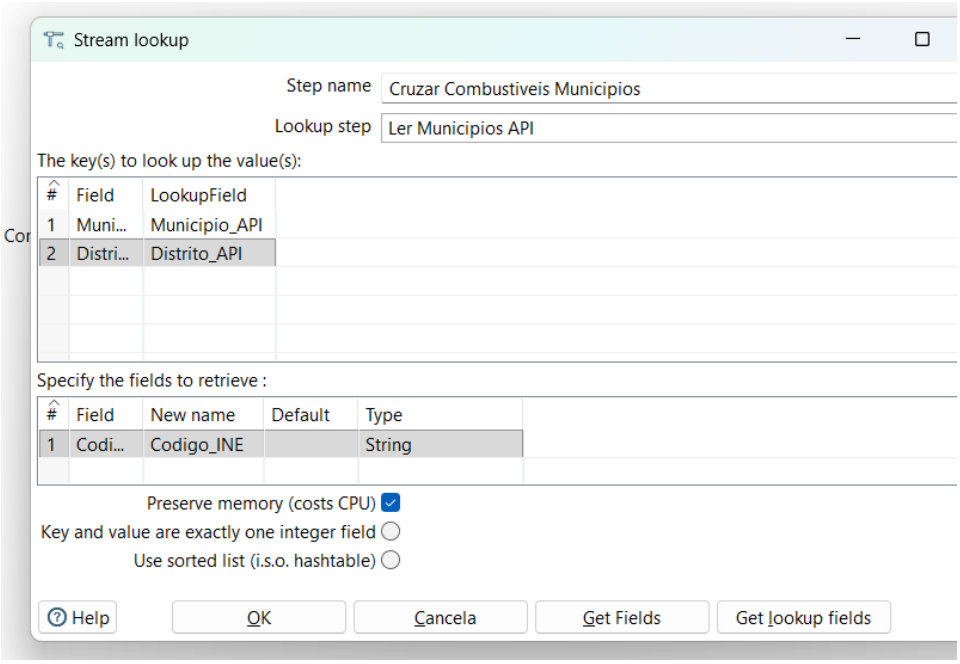


Figura 8 — Configuração do Stream Lookup e associação de Codigo_INE. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

A normalização do caso MEDA/MÊDA foi relevante para evitar que um topónimo com variante de acentuação ficasse sem correspondência. Este tratamento não deve ser interpretado como um dicionário universal de todos os topónimos portugueses: corresponde a uma regra específica documentada e aplicada aos dados da execução.

4.6. Agregação e exportação CSV/XML

4.6.1. Transformação 09 — Sort Rows e Group By

A última transformação é responsável por calcular as estatísticas dos preços de Gasóleo simples e Gasolina simples 95 por município.

O processo começa com a leitura do ficheiro combustiveis_geo_validados.csv, que contém os registos associados aos respetivos códigos INE.

De seguida, é utilizado o passo Sort Rows para ordenar os dados por Distrito, Municipio, Combustivel e Codigo_INE. Esta ordenação é necessária porque o operador Group By trabalha com registos consecutivos do mesmo grupo. Sem ela, os cálculos poderiam produzir resultados incorretos.

O passo "Calcular Estatisticas Combustiveis" utiliza o operador Group By para calcular, em cada grupo, o preço médio, mínimo e máximo através do campo Preco_Numerico. É também calculado o número de registos através da operação Number of rows.

Na execução final, foram obtidos 555 grupos estatísticos. Cada grupo corresponde a uma combinação de distrito, município, combustível e código INE. O campo Numero_Registos representa a quantidade de observações utilizadas no cálculo, não necessariamente o número de postos diferentes.

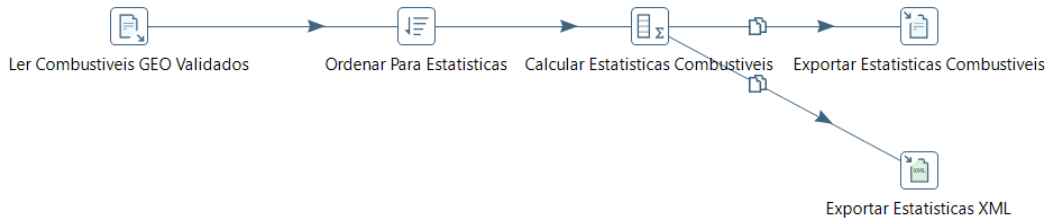


Figura 9 — Transformação 09: ordenação, Group By e exportação para CSV e XML. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

Examine preview data

Rows of step: Calcular Estatisticas Combustiveis (20 rows)

#	Distrito	Municipio	Combustivel	Codigo_INE	Preco_Medio	Preco_Minimo	Preco_Maximo	Numero_Registos
1	Aveiro	Albergaria-a-Velha	Gasolina simples 95	0102	2.12946153846153846154	2,009	2,219	13
2	Aveiro	Albergaria-a-Velha	Gasóleo simples	0102	2.183	2,099	2,259	10
3	Aveiro	Anadia	Gasolina simples 95	0103	2.172	2,029	2,249	10
4	Aveiro	Anadia	Gasóleo simples	0103	2.2159	2,060	2,294	10
5	Aveiro	Arouca	Gasolina simples 95	0104	2.15933333333333333333	1,999	2,249	9
6	Aveiro	Arouca	Gasóleo simples	0104	2.208	2,089	2,294	8
7	Aveiro	Aveiro	Gasolina simples 95	0105	2.15075	2,069	2,182	24
8	Aveiro	Aveiro	Gasóleo simples	0105	2.19342857142857142857	2,092	2,249	21
9	Aveiro	Castelo de Paiva	Gasolina simples 95	0106	2.1384	2,039	2,232	5
1..	Aveiro	Castelo de Paiva	Gasóleo simples	0106	2.187	2,099	2,269	5
1..	Aveiro	Espinho	Gasolina simples 95	0107	2.1934	2,138	2,249	5
1..	Aveiro	Espinho	Gasóleo simples	0107	2.244	2,199	2,294	5
1..	Aveiro	Estarreja	Gasolina simples 95	0108	2.13592857142857142857	1,929	2,254	14
1..	Aveiro	Estarreja	Gasóleo simples	0108	2.17377777777777777778	2,049	2,299	9
1..	Aveiro	Mealhada	Gasolina simples 95	0111	2.18190909090909090909	1,997	2,229	11
1..	Aveiro	Mealhada	Gasóleo simples	0111	2.24788888888888888889	2,087	2,303	9
1..	Aveiro	Murtosa	Gasolina simples 95	0112	2.10733333333333333333	2,059	2,154	3
1..	Aveiro	Murtosa	Gasóleo simples	0112	2.134	2,099	2,169	2
1..	Aveiro	Oliveira de Azeméis	Gasolina simples 95	0113	2.13533333333333333333	1,999	2,229	27
2..	Aveiro	Oliveira de Azeméis	Gasóleo simples	0113	2.17954545454545454545	1,999	2,274	22

Figura 10 — Pré-visualização dos agrupamentos estatísticos. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

O Sort Rows antecede Group By porque, nesta configuração, o operador de agregação reconhece grupos de linhas consecutivas. Os campos que definem o grupo são Distrito, Municipio, Combustivel e Codigo_INE; sobre Preco_Numerico foram calculados média, mínimo e máximo, e a contagem de observações foi obtida separadamente.

4.6.2. Contrato do ficheiro CSV

O CSV final guarda os campos Distrito, Municipio, Combustivel, Codigo_INE, Preco_Medio, Preco_Minimo, Preco_Maximo e Numero_Registos, com codificação UTF-8. O delimitador é ponto e vírgula, o que facilita a distinção relativamente à vírgula decimal usada na apresentação dos preços com três casas decimais. Cada linha corresponde ao grupo territorial e de combustível, e não a um posto de abastecimento isolado.

4.6.3. Exportação XML e conferência de conteúdos

A saída XML foi adicionada à transformação 09, sem substituir a exportação CSV. O elemento raiz é EstatisticasCombustiveis; cada registo é identificado por Estatistica e contém os mesmos oito campos do CSV.

Os três valores monetários foram formatados com três casas decimais e ponto como separador decimal. A cópia de linhas a partir do Group By assegura que os mesmos grupos são enviados para os dois exportadores.

Na primeira verificação surgiu um ficheiro com extensão duplicada (.xml.xml). O nome configurado foi corrigido para terminar uma única vez em .xml, e a transformação foi executada novamente.

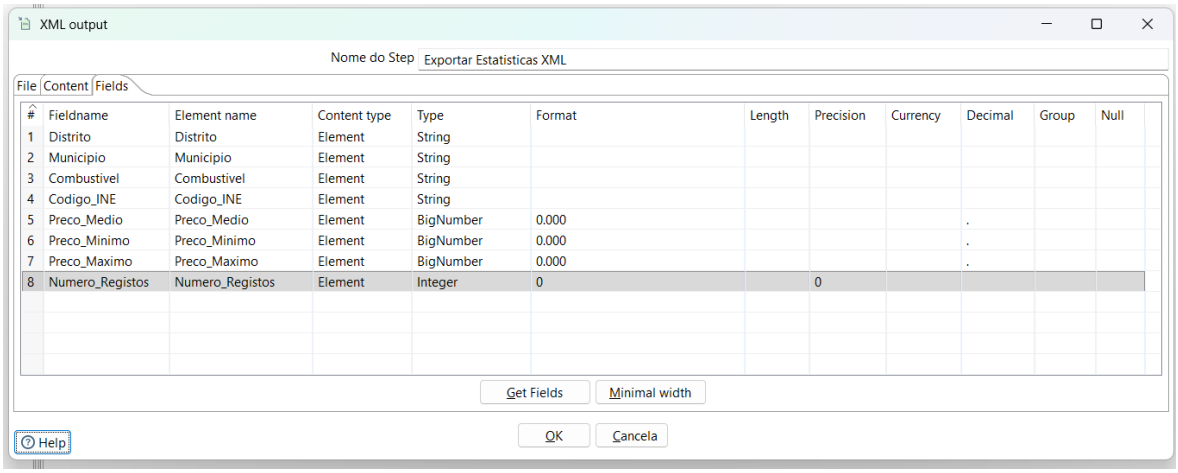


Figura 11 — Configuração do XML Output para escrever estatísticas territoriais. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

A inspeção no editor confirmou a raiz EstatisticasCombustiveis, os elementos Estatistica e os valores de preço com separador ponto. Também se verificou a preservação dos zeros iniciais em Codigo_INE.

Por exemplo, um registo XML inclui Distrito Aveiro, Municipio Albergaria-a-Velha, Combustivel Gasolina simples 95 e Codigo_INE 0102, seguido das quatro medidas estatísticas.

A estrutura XML permite reutilizar o resultado com ferramentas que necessitem de um documento hierárquico. Não foi implementada uma validação adicional contra esquema XSD.

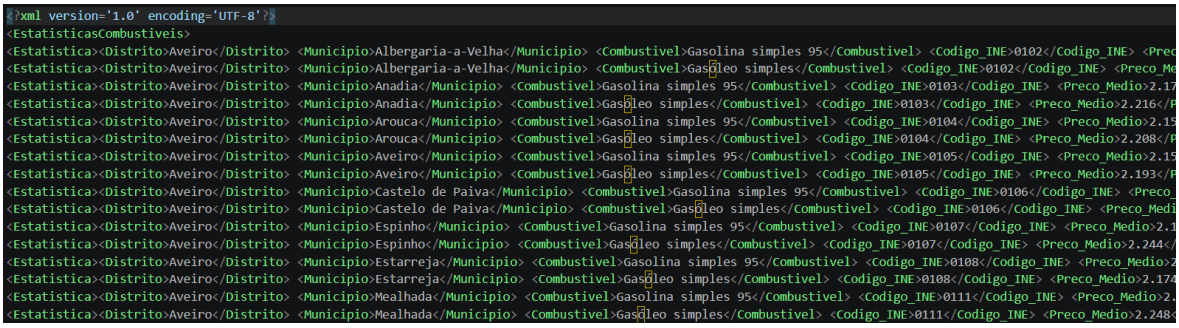
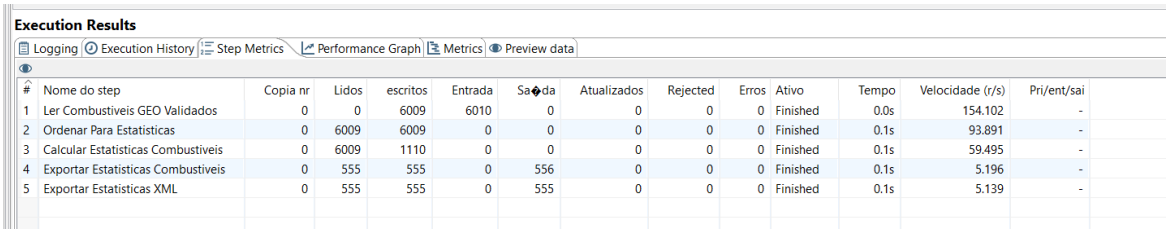


Figura 12 — Verificação do XML: atributos, preços e códigos INE com zeros iniciais. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

A leitura do documento XML permite verificar se o formato de saída corresponde ao que foi configurado no XML Output. Cada elemento Estatistica contém o distrito, o município, o combustível, o código INE e as quatro medidas. A diferença entre 2,129 no CSV e 2.129 no XML resulta apenas da convenção do separador decimal definida em cada exportador.

Foi igualmente confirmado que os códigos INE com zero inicial se mantiveram como texto. A validação efetuada nesta fase consistiu na inspeção do ficheiro produzido e nas métricas de escrita; não foi aplicado um esquema XSD nem se afirma que essa validação adicional tenha sido executada.



Execution Results

Logging | Execution History | Step Metrics | Performance Graph | Metrics | Preview data

#	Nome do step	Copia nr	Lidos	escritos	Entrada	Sa◆da	Atualizados	Rejected	Erros	Ativo	Tempo	Velocidade (r/s)	Pri/ent/sai
1	Ler Combustiveis GEO Validados	0	0	6009	6010	0	0	0	0	Finished	0.0s	154.102	-
2	Ordenar Para Estatisticas	0	6009	6009	0	0	0	0	0	Finished	0.1s	93.891	-
3	Calcular Estatisticas Combustiveis	0	6009	1110	0	0	0	0	0	Finished	0.1s	59.495	-
4	Exportar Estatisticas Combustiveis	0	555	555	0	556	0	0	0	Finished	0.1s	5.196	-
5	Exportar Estatisticas XML	0	555	555	0	555	0	0	0	Finished	0.1s	5.139	-

Figura 13 — Métricas da transformação: 555 grupos escritos em cada saída. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

O relatório documenta a escrita de 555 registos em cada formato e a inspeção dos respetivos campos. Não existe evidência de validação do XML contra um XSD.

5. Workflow de integração em KNIME

5.1. Organização e extração de fontes

Tabela 4 — Fases e operações do workflow KNIME

Fase	Operações realizadas	Resultado
Extração	Leitura de CSV, JSON e XML; extração de atributos relevantes.	Tabelas iniciais no KNIME.
Transformação	Conversão de preços, normalização de marcas, tratamento de valores em falta, remoção de duplicados, filtragem e preparação de coordenadas.	Tabelas com tipos e valores mais consistentes.
Integração	Associação dos dados CSV e JSON e junção do catálogo XML.	Tabela consolidada com os campos selecionados.
Carregamento	Seleção das colunas finais e utilização do CSV Writer.	Ficheiro resultado_final.csv.

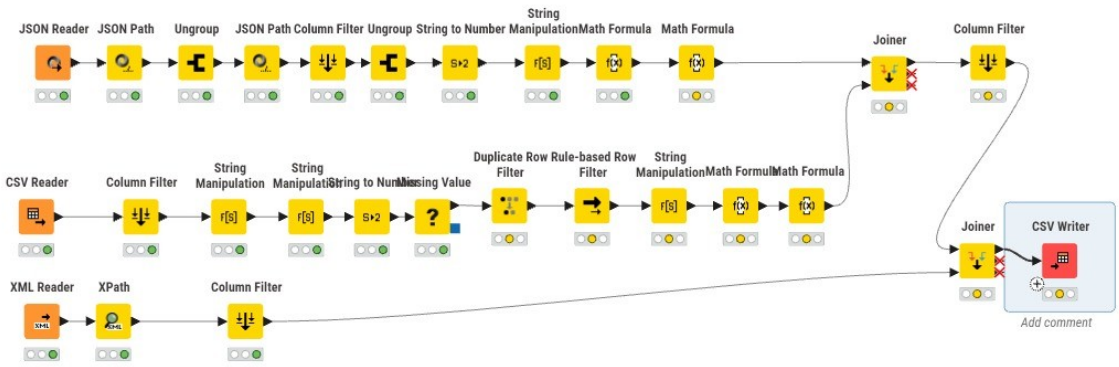


Figura 14 — Workflow completo do KNIME: três fontes de entrada, operações de tratamento, dois Joiner e CSV Writer. Fonte: captura real fornecida pelo elemento responsável pelo KNIME.

As etapas seguintes descrevem os nós KNIME usados para preparar CSV, JSON e XML, efetuar junções e exportar a tabela consolidada.

5.2. Preparação do CSV

A leitura do CSV é realizada através do nó de importação de ficheiros CSV. A tabela contém campos associados aos postos, à localização administrativa, ao combustível, ao preço e às coordenadas. Antes de integrar esta fonte com as restantes, foi necessário assegurar que os campos utilizados em cálculos ou comparações tinham tipos de dados adequados.

5.2.1. Conversão dos preços

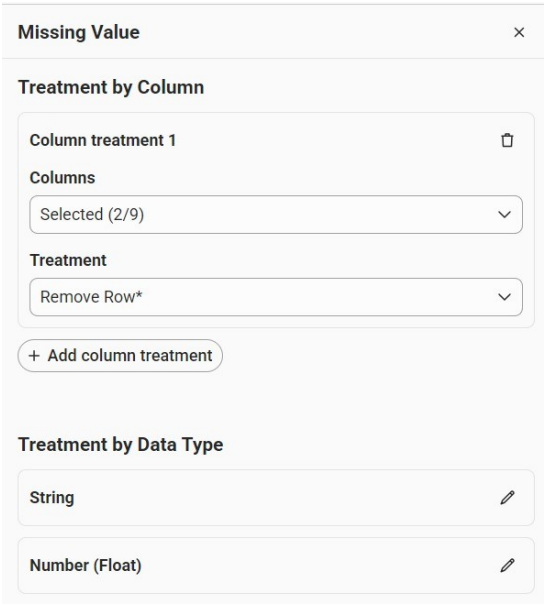
Os preços encontravam-se representados com vírgula como separador decimal, por exemplo, no formato textual “1,659”. Para permitir operações numéricas e ordenação correta, a representação decimal foi normalizada e a coluna Preco foi convertida para um tipo numérico através de nós de manipulação de texto e conversão de tipos.

5.2.2. Missing Value, duplicados e filtragem

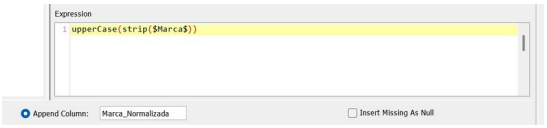
Na preparação do CSV foram aplicados tratamento de valores em falta, controlo de duplicados e filtragem. A seleção dos campos de comparação pode influenciar os registos conservados, pelo que estas regras devem ser lidas em conjunto com as capturas reais apresentadas abaixo.

A definição de duplicado depende das colunas escolhidas: dois registos com valores iguais nesses campos são considerados repetidos mesmo que existam diferenças noutros campos não incluídos na chave. Por esse motivo, a escolha dos campos deve ser entendida como uma regra de negócio do processo.

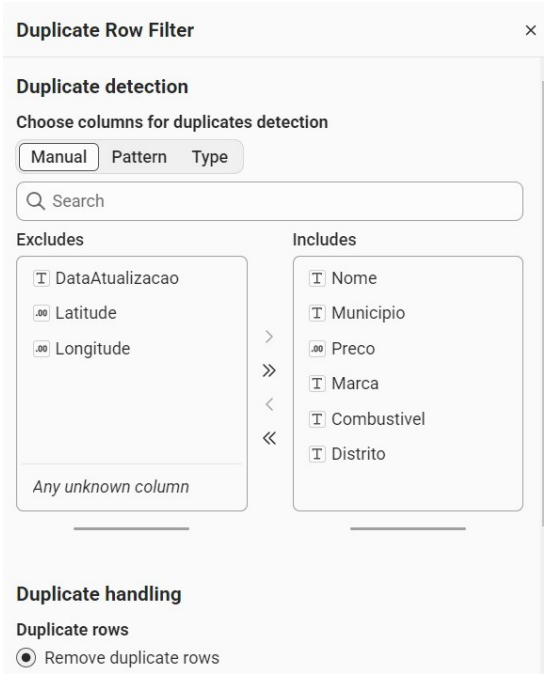
Foi aplicada uma regra para excluir registos cujo preço não fosse superior a zero, removendo valores que não representam preços válidos para a comparação pretendida. Os nomes das marcas foram também normalizados para reduzir diferenças de escrita e facilitar a correspondência entre fontes. A normalização textual é relevante porque pequenas diferenças de maiúsculas, espaços ou grafia podem impedir a associação de registos equivalentes.



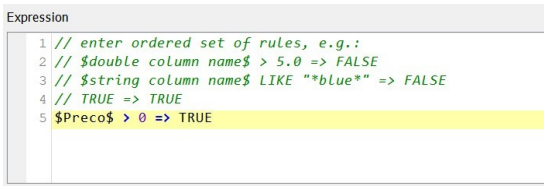
a) Missing Value: Remove Row em 2 de 9 colunas selecionadas.



c) Normalização da marca com upperCase(strip()).



b) Duplicate Row Filter: seis campos de comparação.



d) Filtro de preços superiores a zero.

Figura 15 — Regras de limpeza e validação da origem CSV no KNIME. Fonte: capturas reais do workflow.

A configuração agora ilustrada do Missing Value mostra o tratamento “Remove Row” aplicado a duas das nove colunas da tabela, sem identificar os respetivos nomes na captura. O Duplicate Row Filter compara Nome, Municipio, Preco, Marca, Combustivel e Distrito, excluindo DataAtualizacao, Latitude e Longitude dessa regra. O filtro de preços utiliza a condição Preco > 0; a normalização da marca usa upperCase(strip($Marca$)). As contagens de linhas removidas por cada operação não estão documentadas.

5.3. Tratamento do JSON e das coordenadas

5.3.1. Extração de atributos com JSON Path e Ungroup

A fonte JSON foi obtida a partir de uma camada de serviço ArcGIS associada aos postos de abastecimento. A resposta contém metadados e uma coleção de entidades. Para transformar a estrutura hierárquica em linhas de tabela, foram utilizados nós JSON Path e operações de expansão de listas, permitindo aceder aos atributos de cada entidade.

Entre os campos extraídos encontram-se o identificador do objeto (objectid), a marca, as coordenadas nlatitude e nlongitude e outros identificadores disponibilizados pela fonte, como inspireid, thematicid e globalid. Os campos auxiliares usados durante a extração foram posteriormente filtrados quando deixaram de ser necessários.

As coordenadas foram convertidas para valores numéricos e os nomes das marcas foram normalizados segundo uma lógica compatível com a aplicada à fonte CSV. Esta preparação torna os campos mais adequados para a comparação e associação entre tabelas.

#	RowID	objectid String	marca String	nlatitude Number (Float)	nlongitude Number (Float)	inspireid String	thematicid String	globalid String	Marca_Normal... String	Lat_aprox Number (Float)
1	Row0...	4589	BP	41.507	-6.286	IDDGEG_PACVR_...	IDDGEG_Infraest...	{030EB5CD-A913...	BP	41.507
2	Row0...	4990	Q8	40.915	-8.496	IDDGEG_PACVR_...	IDDGEG_Infraest...	{31FA8B21-EB3F...	Q8	40.915
3	Row0...	5392	VALCARCE	41.757	-7.263	IDDGEG_PACVR_...	IDDGEG_Infraest...	{642DD3F6-DF34...	VALCARCE	41.757
4	Row0...	5397	PRIO	41.169	-8.572	IDDGEG_PACVR_...	IDDGEG_Infraest...	{8F7208F2-F069-...	PRIO	41.169
5	Row0...	5400	SHELL	41.218	-8.695	IDDGEG_PACVR_...	IDDGEG_Infraest...	{48CF2E96-6A32...	SHELL	41.218
6	Row0...	2926	GALP	39.477	-8.34	IDDGEG_PACVR_...	IDDGEG_Infraest...	{2505A0F7-CE67...	GALP	39.477

Figura 16 — Amostra de dados geográficos JSON extraídos para colunas no KNIME, incluindo objectid, marca, coordenadas e campos auxiliares; o encadeamento dos nós JSON Reader, JSON Path e Ungroup encontra-se na Figura 14.

5.3.2. Conversão e aproximação das coordenadas

As coordenadas podem apresentar pequenas diferenças de precisão entre fontes, mesmo quando se referem a localizações próximas. Para apoiar a correspondência, foram criadas colunas auxiliares com coordenadas arredondadas a três casas decimais, através de fórmulas equivalentes a round(coordenada × 1000) / 1000.

Esta operação reduz a precisão decimal utilizada na comparação e pode facilitar a correspondência quando os valores originais diferem ligeiramente. Contudo, o arredondamento também reduz a precisão espacial: três casas decimais correspondem aproximadamente a uma centena de metros em latitude, pelo que podem existir localizações distintas com coordenadas arredondadas iguais. Assim, este método deve ser entendido como uma aproximação e não como uma identificação geográfica exata.

As colunas auxiliares de coordenadas aproximadas foram utilizadas no processo de preparação da integração. A qualidade final das correspondências depende igualmente das outras chaves configuradas no Joiner e da consistência dos dados de origem.

Expression

```
1 round($nlatitude$ * 1000) / 1000
```

*Figura 17 — Expressão real de arredondamento da latitude a três casas decimais no KNIME: round($nlatitude$ * 1000) / 1000.*

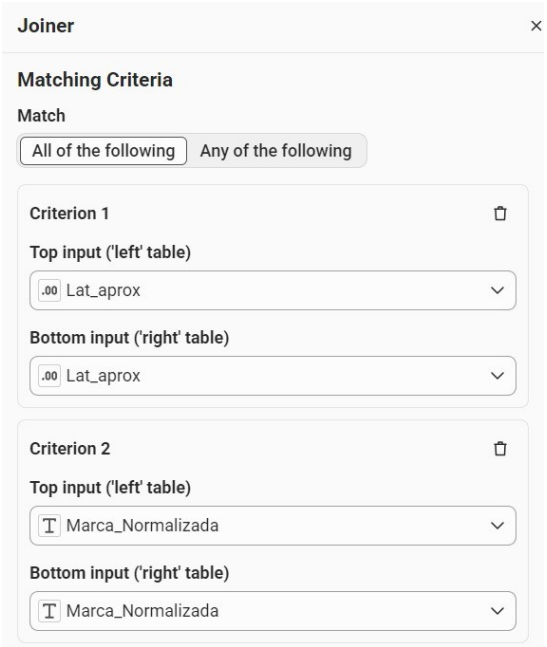
5.4. Joiner entre CSV e JSON

A integração das tabelas CSV e JSON foi realizada através do nó Joiner. Este nó permite associar linhas de duas tabelas com base em campos de correspondência configurados. Antes da junção, foram preparados campos de marca e coordenadas, de modo a reduzir diferenças de representação entre as fontes.

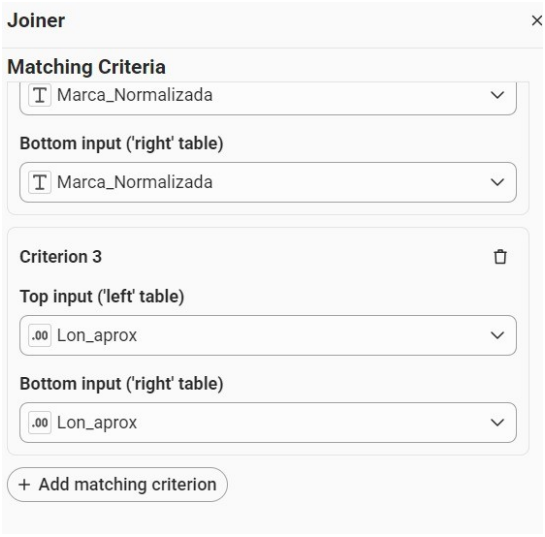
A junção foi configurada para exigir simultaneamente três correspondências entre as duas tabelas: Lat_aprox, Marca_Normalizada e Lon_aprox. As capturas dos critérios de matching

permitem confirmar estes campos e a opção “All of the following”, mas não indicam o modo de junção selecionado. A execução do workflow produziu 5.466 linhas, resultado que requer verificação amostral para excluir correspondências múltiplas ou incorretas.

Após a junção, foram selecionadas as colunas relevantes para a etapa seguinte, evitando transportar campos auxiliares desnecessários para a saída final. A validação das associações deve considerar amostras reais de registos, comparando os atributos das duas fontes e verificando se as marcas e localizações correspondem.



a) Lat_aprox e Marca_Normalizada; opção “All of the following”.



b) Continuação: Marca_Normalizada e Lon_aprox.

Figura 18 — Critérios documentados do Joiner CSV + JSON: correspondência simultânea por latitude aproximada, marca normalizada e longitude aproximada.

5.5. Integração do catálogo XML

O catálogo XML foi criado para representar os combustíveis de forma estruturada, contendo um código, um nome e uma unidade de medida. O conteúdo inclui os seguintes pares: G95 — Gasolina simples 95 — litro; GASOLEO — Gasóleo simples — litro.

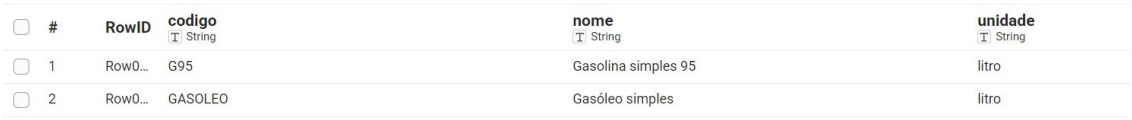
Na preparação inicial, a leitura do XML exigiu ajustar o processo de importação para que os elementos fossem interpretados como linhas e colunas, em vez de permanecerem apenas como conteúdo textual numa única célula. Foi utilizado um nó XPath para extrair os elementos codigo, nome e unidade, configurando a saída para produzir múltiplas linhas. Um nó Column Filter foi depois utilizado para manter os campos necessários.

A tabela resultante do catálogo foi integrada na tabela principal através de um Joiner, relacionando o campo de combustível com o campo nome do catálogo. A junção permite acrescentar o código e a unidade ao registo quando existe correspondência entre os nomes. A utilização de uma junção interna (Inner Join) significa que apenas são mantidas as linhas que satisfazem a condição de correspondência.

Na execução reportada, o resultado manteve 5 466 linhas após a integração do catálogo. A manutenção da contagem é consistente com a existência de correspondências para as linhas de entrada, mas a verificação de valores não correspondidos continua a ser uma boa prática de validação.

Tabela 5 — Conteúdo do catálogo XML descrito no relatório KNIME

Código	Designação no catálogo XML	Unidade
G95	Gasolina simples 95	litro
GASOLEO	Gasóleo simples	litro



#	RowID	codigo (String)	nome (String)	unidade (String)
1	Row0...	G95	Gasolina simples 95	litro
2	Row0...	GASOLEO	Gasóleo simples	litro

Figura 19 — Catálogo XML do KNIME após extração por XPath: códigos G95 e GASOLEO, nomes de combustível e unidade litro. Os nós XML Reader, XPath e Joiner são visíveis na Figura 14.

5.6. Exportação e consulta do resultado

Após as operações de integração, foi utilizado um nó Column Filter para selecionar os campos que interessam à utilização final e excluir colunas auxiliares ou técnicas que já não são necessárias. A seleção deve preservar os dados úteis à análise, como o combustível, o preço e a localização, bem como os campos de referência acrescentados pelo catálogo.

O nó CSV Writer foi utilizado para exportar a tabela resultante para o ficheiro resultado_final.csv. A exportação permite utilizar o conjunto integrado fora do KNIME, por exemplo numa folha de cálculo ou noutra ferramenta de análise. A interpretação correta do separador de colunas depende das opções de exportação e da configuração regional da aplicação que abre o ficheiro.

O ficheiro foi aberto no Excel e, após ajustar a importação para reconhecer o delimitador correto e alargar a coluna da data quando necessário, os dados ficaram organizados em colunas. Foram testadas funções de filtragem por combustível e município e a ordenação do preço por ordem crescente.

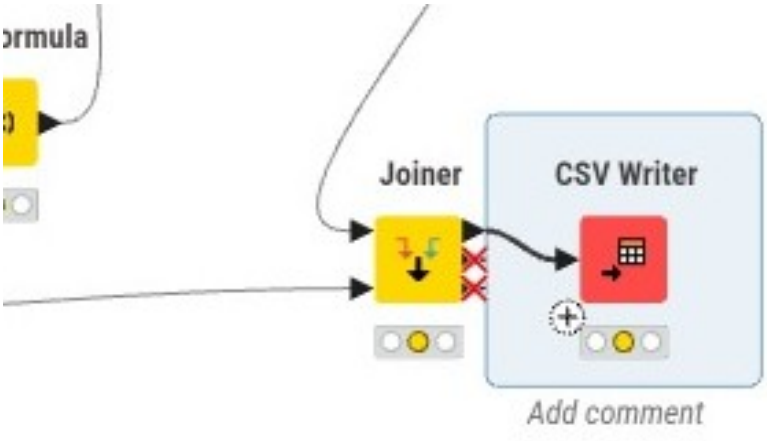


Figura 20 — Pormenor do workflow KNIME com o nó CSV Writer ligado à saída do segundo Joiner. A imagem não mostra os parâmetros internos de configuração do nó.

Lat_apro	Lon_apro	Nome	Municipio	Preç	Combustivel	DataAtualizacao	Distrito
40.362	-7.343	INTERMARCHÉ BELMONTE	Belmonte	1.959	Gasolina simples 95	13/10/2026 10:40	Castelo Branco
40.271	-7.494	INTERMARCHÉ Covilhã	Covilhã	1.999	Gasolina simples 95	13/10/2026 16:15	Castelo Branco
40.152	-7.498	Intermarché Fundão	Fundão	2.004	Gasolina simples 95	12/10/2026 20:00	Castelo Branco
39.812	-8.108	Intermarché da Sertã	Sertã	2.009	Gasolina simples 95	13/10/2026 09:20	Castelo Branco
39.809	-7.525	INTERMARCHÉ CASTELO BRANCO	Castelo Branco	2.019	Gasolina simples 95	13/10/2026 07:30	Castelo Branco
39.751	-7.918	INTERMARCHÉ-Superproença-Supermercados,lda	Proença-a-Nova	2.019	Gasolina simples 95	13/10/2026 08:55	Castelo Branco
40.362	-7.343	INTERMARCHÉ BELMONTE	Belmonte	2.029	Gasóleo simples	13/10/2026 10:40	Castelo Branco
40.268	-7.505	PETROPRIX Covilhã	Covilhã	2.039	Gasóleo simples	12/10/2026 20:40	Castelo Branco
39.916	-7.465	INTERMARCHÉ ALCAINS	Castelo Branco	2.039	Gasolina simples 95	13/10/2026 07:30	Castelo Branco
39.93	-7.241	INTERMARCHÉ IDANHA-A-NOVA	Idanha-a-Nova	2.039	Gasolina simples 95	13/10/2026 07:30	Castelo Branco
39.933	-7.238	AGL Energias Renováveis, Lda - REDE ENERGIA Idanha a No	Idanha-a-Nova	2.039	Gasolina simples 95	13/10/2026 08:30	Castelo Branco
40.152	-7.498	Intermarché Fundão	Fundão	2.044	Gasóleo simples	12/10/2026 20:00	Castelo Branco
40.271	-7.494	INTERMARCHÉ Covilhã	Covilhã	2.049	Gasóleo simples	13/10/2026 16:15	Castelo Branco
40.268	-7.505	PETROPRIX Covilhã	Covilhã	2.059	Gasolina simples 95	12/10/2026 20:40	Castelo Branco
39.812	-8.108	Intermarché da Sertã	Sertã	2.059	Gasóleo simples	13/10/2026 09:20	Castelo Branco
39.749	-7.917	J. LOURENÇO - PROENÇA	Proença-a-Nova	2.063	Gasolina simples 95	12/10/2026 09:30	Castelo Branco
39.808	-7.518	J. LOURENÇO - CASTELO BRANCO	Castelo Branco	2.063	Gasolina simples 95	12/10/2026 09:30	Castelo Branco
39.809	-7.525	INTERMARCHÉ CASTELO BRANCO	Castelo Branco	2.069	Gasóleo simples	13/10/2026 07:30	Castelo Branco
39.751	-7.918	INTERMARCHÉ-Superproença-Supermercados,lda	Proença-a-Nova	2.069	Gasóleo simples	13/10/2026 08:55	Castelo Branco
39.916	-7.465	INTERMARCHÉ ALCAINS	Castelo Branco	2.079	Gasóleo simples	13/10/2026 07:30	Castelo Branco
39.93	-7.241	INTERMARCHÉ IDANHA-A-NOVA	Idanha-a-Nova	2.079	Gasóleo simples	13/10/2026 07:30	Castelo Branco
39.933	-7.238	AGL Energias Renováveis, Lda - REDE ENERGIA Idanha a No	Idanha-a-Nova	2.079	Gasóleo simples	13/10/2026 08:30	Castelo Branco

Figura 21 — Registos da exportação KNIME apresentados no Excel, com dados de município, combustível, preço, coordenadas e data de atualização.

6. Jobs, execução e apresentação

6.1. Job principal no Kettle

O Job 10_job_principal_etl.kjb executa, pela ordem estabelecida, as oito transformações do projeto. As entradas estão ligadas por condições de sucesso; cada transformação possui também uma ligação de falha para “ERRO - Interromper ETL”.

Na execução final, o histórico confirmou a conclusão com sucesso das oito transformações, após as dependências serem corrigidas.

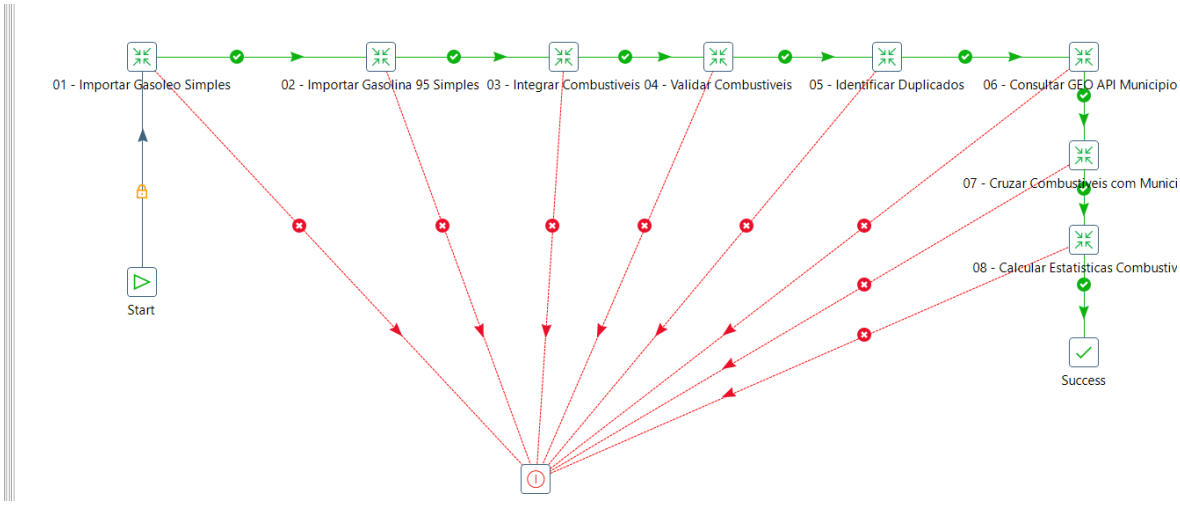


Figura 22 — Job principal: Start, oito transformações e caminhos de sucesso/falha. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

6.1.1. Sequência e dependências

A ordem do Job respeita a dependência entre os ficheiros: importação individual de cada combustível; integração; validação de preço; identificação de duplicados; consulta à GEO API; cruzamento municipal; cálculo e exportação das estatísticas.

As entradas do Job seguem a numeração operacional 01 a 08, mas invocam os oito ficheiros .ktr efetivos, identificados pelos prefixos 01 e 03 a 09.

6.1.2. Ligações condicionais e Abort

As ligações verdes estão configuradas para avançar após sucesso. As vermelhas saem de cada transformação quando a execução falha e convergem em “ERRO - Interromper ETL”.

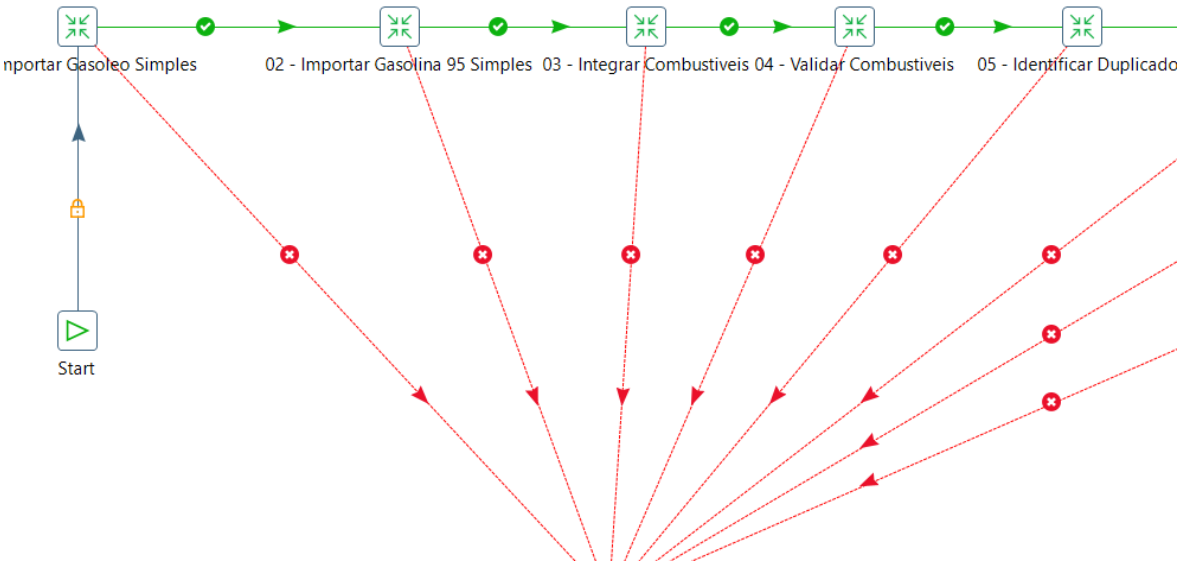


Figura 23 — Detalhe das ligações condicionais de sucesso e falha no Job. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

6.2. Testes e histórico da execução

Numa fase de teste, o Spoon indicou sucesso no Job mas o histórico mostrava apenas as duas primeiras transformações. O problema foi identificado nas ligações condicionais entre etapas. Depois de as configurar corretamente, o Job passou a percorrer as oito transformações.

A primeira execução indicou «Sucesso», mas o histórico revelou que apenas duas transformações tinham sido executadas. Após corrigir as ligações, o histórico confirmou a execução das oito transformações até Success.

O histórico da execução final apresenta as entradas 01 a 08 concluídas como “Sucesso”, seguidas da entrada Success e do término normal do Job. Não há evidência, nesse teste, de acionamento do ramo de interrupção.

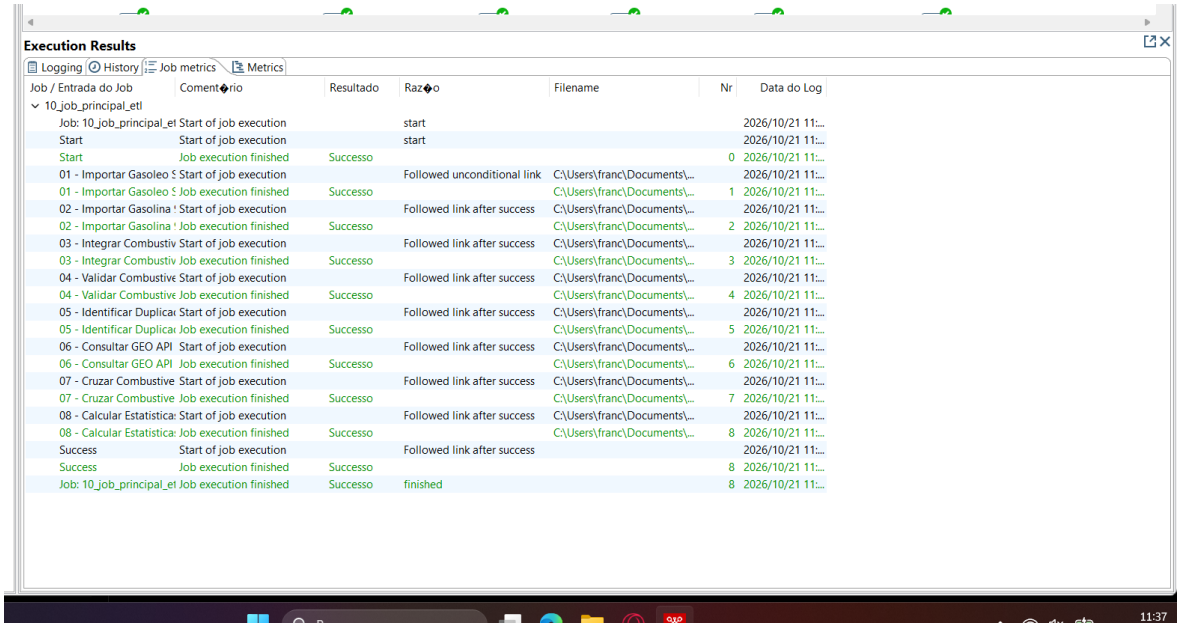


Figura 24 — Histórico de execução completo do Job, com as oito transformações concluídas. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

No KNIME, a execução é feita pelo encadeamento de nós. Não há Job de orquestração adicional documentado.

6.3. Node-RED e dashboard

6.3.1. Leitura do CSV e percurso HTTP

A integração com Node-RED começa pela leitura do ficheiro estatisticas_combustiveis.csv. Assim, o dashboard utiliza os resultados já calculados no Pentaho, sem repetir regras de validação geográfica ou médias.

O fluxo foi dividido em dois percursos: um HTTP In → Read File → CSV → HTTP Response, que devolve os dados como JSON; e um Inject → Read File → CSV → UI Table, com ligação por clique a Change → UI Chart.

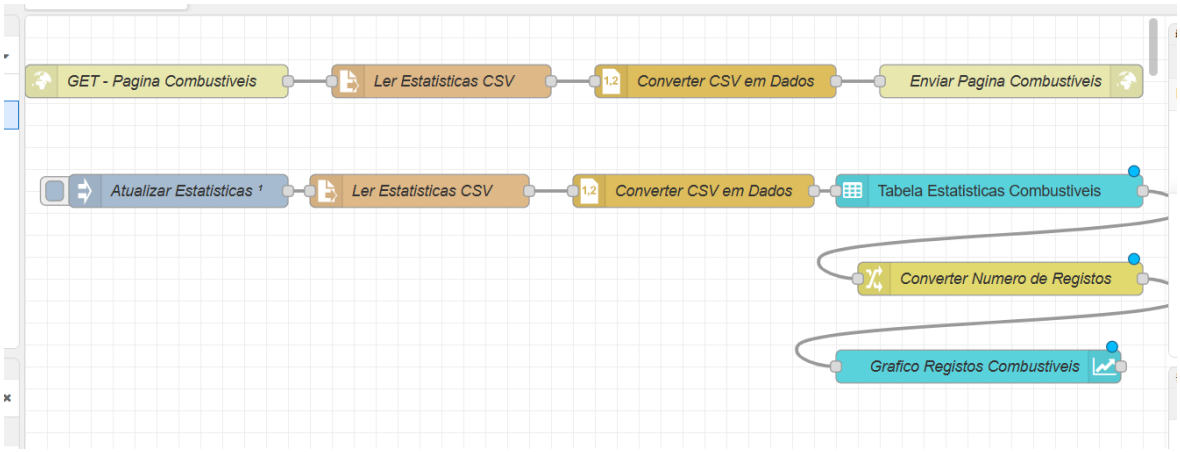


Figura 25 — Fluxo Node-RED: leitura do CSV final, endpoint HTTP, tabela e gráfico. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

O endpoint GET /combustiveis disponibiliza as estatísticas pela rede local do computador onde o Node-RED está a correr. Foi utilizada a leitura do CSV como texto e a sua conversão em objetos antes do HTTP Response.

O teste foi realizado pelo navegador e demonstrou uma resposta em JSON com os campos da tabela estatística. Não existe nesta versão filtragem parametrizada no endpoint HTTP; todos os grupos são devolvidos.

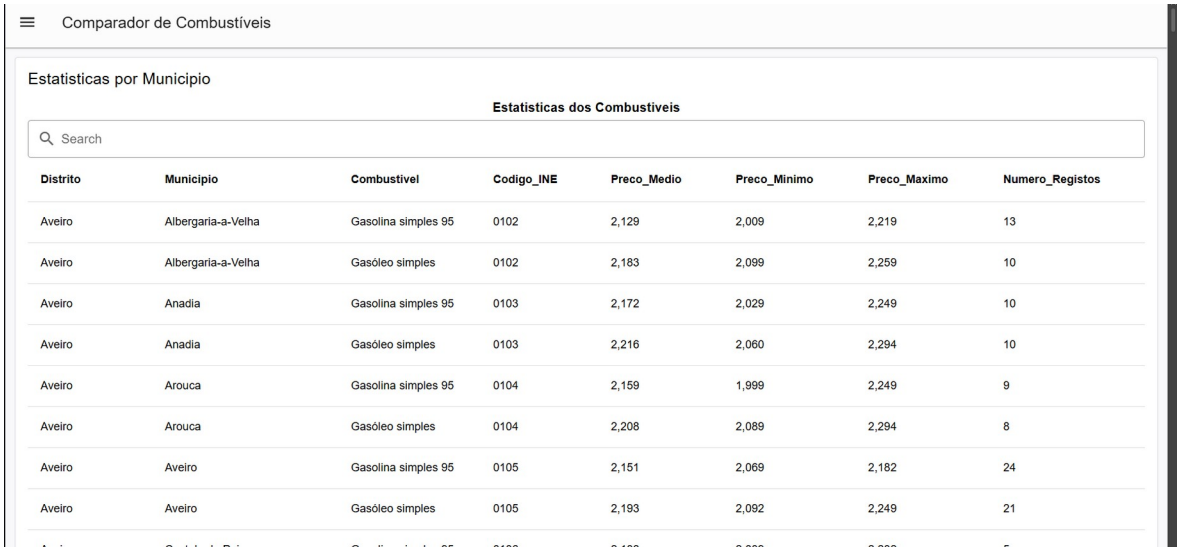
Exemplo de registo devolvido pelo endpoint (a partir do ficheiro estatisticas_combustiveis.csv):

{ "Distrito": "Aveiro", "Municipio": "Albergaria-a-Velha", "Combustivel": "Gasolina simples 95", "Codigo_INE": "0102", "Preco_Medio": "2,129", "Preco_Minimo": "2,009", "Preco_Maximo": "2,219", "Numero_Registos": "13" }

6.3.2. Interface FlowFuse Dashboard

O FlowFuse Dashboard 2.0 apresenta os 555 grupos num UI Table com pesquisa. O Inject lê o CSV quando acionado; os campos apresentados correspondem à exportação do Kettle.

Foi criado um grupo visual com largura de 12 colunas, permitindo apresentar simultaneamente os oito campos sem cortar a tabela. O Inject faz a leitura do CSV ao fazer Deploy e também pode ser acionado manualmente.



Distrito	Municipio	Combustivel	Codigo_INE	Preco_Medio	Preco_Minimo	Preco_Maximo	Numero_Registos
Aveiro	Albergaria-a-Velha	Gasolina simples 95	0102	2,129	2,009	2,219	13
Aveiro	Albergaria-a-Velha	Gasóleo simples	0102	2,183	2,099	2,259	10
Aveiro	Anadia	Gasolina simples 95	0103	2,172	2,029	2,249	10
Aveiro	Anadia	Gasóleo simples	0103	2,216	2,060	2,294	10
Aveiro	Arouca	Gasolina simples 95	0104	2,159	1,999	2,249	9
Aveiro	Arouca	Gasóleo simples	0104	2,208	2,089	2,294	8
Aveiro	Aveiro	Gasolina simples 95	0105	2,151	2,069	2,182	24
Aveiro	Aveiro	Gasóleo simples	0105	2,193	2,092	2,249	21

Figura 26 — Dashboard FlowFuse com os grupos estatísticos e campo de pesquisa. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

A tabela apresenta Distrito, Municipio, Combustivel, Codigo_INE, Preco_Medio, Preco_Minimo, Preco_Maximo e Numero_Registos. Os dados correspondem aos campos do CSV, permitindo comparar diretamente os valores da interface com os ficheiros produzidos.

A caixa Search pesquisa texto nas colunas, mas distingue variantes com e sem acento, como “Gasoleo” e “Gasóleo”. Isso constitui uma limitação da configuração atual e não um erro no processamento ETL.

Distrito	Municipio	Combustivel	Codigo_INE	Preco_Medio	Preco_Minimo	Preco_Maximo	Numero_Registos
Aveiro	Albergaria-a-Velha	Gasolina simples 95	0102	2,129	2,009	2,219	13
Aveiro	Albergaria-a-Velha	Gasóleo simples	0102	2,183	2,099	2,259	10
Aveiro	Anadia	Gasolina simples 95	0103	2,172	2,029	2,249	10
Aveiro	Anadia	Gasóleo simples	0103	2,216	2,060	2,294	10
Aveiro	Arouca	Gasolina simples 95	0104	2,159	1,999	2,249	9
Aveiro	Arouca	Gasóleo simples	0104	2,208	2,089	2,294	8
Aveiro	Aveiro	Gasolina simples 95	0105	2,151	2,069	2,182	24
Aveiro	Aveiro	Gasóleo simples	0105	2,193	2,092	2,249	21

Figura 27 — Detalhe das colunas estatísticas exibidas no dashboard. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

6.3.3. Gráfico e interação do utilizador

O UI Chart apresenta Numero_Registos, e não os preços. Ao selecionar uma linha do UI Table, o nó Change converte o valor através de JSONata $number(payload.Numero_Registos) e remove msg.action. As séries são distinguidas por Combustivel.

As séries são separadas pelo campo Combustivel, o eixo horizontal utiliza Municipio e o vertical Numero_Registos. A seleção das linhas de um mesmo município permite confrontar as contagens dos dois combustíveis.

No exemplo de Albergaria-a-Velha, surgiram 13 observações de Gasolina simples 95 e 10 de Gasóleo simples. Estes valores representam o volume de observações usado nas médias, não necessariamente o número de postos distintos.

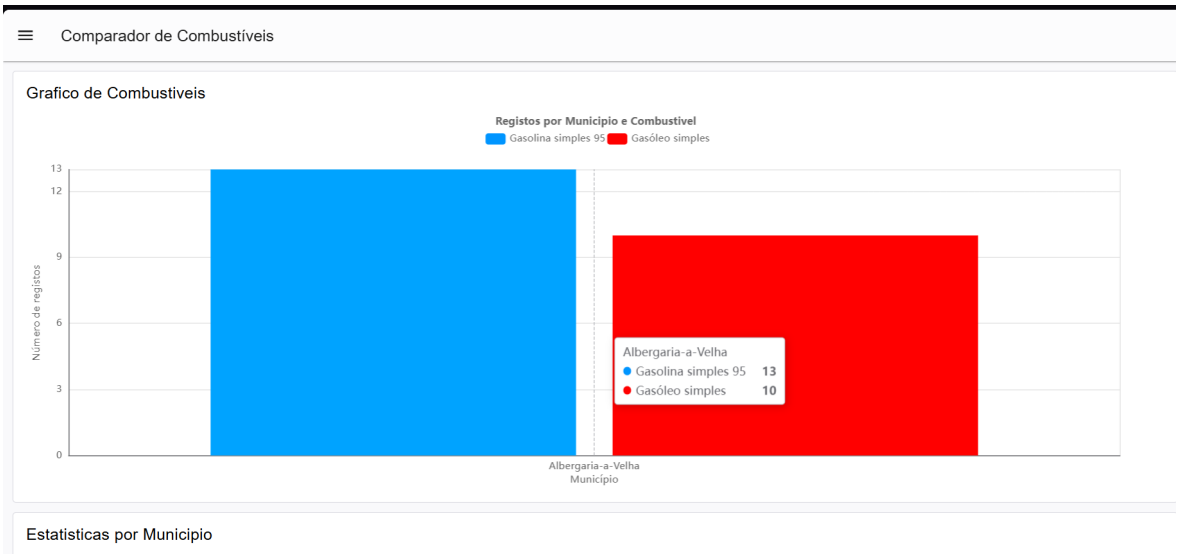


Figura 28 — Gráfico no Node-RED do número de observações por combustível em Albergaria-a-Velha. Fonte: captura da implementação em Pentaho Kettle/Node-RED.

7. Resultados e análise

7.1. Indicadores da implementação Kettle

Após validação, deduplicação e associação geográfica, o Kettle manteve 6.009 observações. O Group By gerou 555 grupos por distrito, município, combustível e código INE.

Os ficheiros de exceção do preço, duplicados e correspondência geográfica não continham linhas de dados nesta execução.

Tabela 6 — Reconciliação do volume de observações e grupos no Kettle

Etapa	Válidos / agregados	Rejeitados
Validação de preço	6.009	0
Identificação de duplicados	6.009	0
Validação geográfica	6.009	0
Agregação estatística	555 grupos	—

7.1.1. Caso de Aveiro

No município de Aveiro, o CSV final apresenta 24 observações de Gasolina simples 95, com preço médio de 2,151 €/L, mínimo de 2,069 €/L e máximo de 2,182 €/L.

Para o Gasóleo simples, foram obtidas 21 observações, média de 2,193 €/L, mínimo de 2,092 €/L e máximo de 2,249 €/L. Trata-se de valores da recolha, sem análise de evolução temporal.

Tabela 7 — Preços calculados para Aveiro, conforme a amostra utilizada

Produto	Média (€)	Mínimo (€)	Máximo (€)	Observações
Gasolina simples 95	2,151	2,069	2,182	24
Gasóleo simples	2,193	2,092	2,249	21

7.1.2. Caso de Albergaria-a-Velha

Albergaria-a-Velha apresenta 13 observações de Gasolina simples 95, com média de 2,129 €/L, mínimo de 2,009 €/L e máximo de 2,219 €/L. O código INE do município é 0102.

Para o Gasóleo simples existem 10 observações, média de 2,183 €/L, mínimo de 2,099 €/L e máximo de 2,259 €/L. Estes dois valores de contagem foram reproduzidos no gráfico do Node-RED.

Tabela 8 — Preços calculados para Albergaria-a-Velha, conforme a amostra utilizada

Produto	Média (€)	Mínimo (€)	Máximo (€)	Observações
Gasolina simples 95	2,129	2,009	2,219	13
Gasóleo simples	2,183	2,099	2,259	10

7.1.3. Evidências globais

A evidência inclui métricas dos passos no Spoon, inspeção de ficheiros CSV/XML e consulta dos resultados no dashboard. A Tabela 9 distingue o que foi verificado do que permanece por testar.

Não foram documentados testes de indisponibilidade da API, preços artificialmente inválidos, alterações do esquema dos CSV nem validação do XML contra XSD. São cenários relevantes para uma evolução posterior, mas não devem ser apresentados como testes já concluídos.

Tabela 9 — Resultados observados e alcance das verificações da execução Kettle

Verificação	Evidência observada	Interpretação
Validação de preço	6.009 aceites; 0 rejeitados	Não houve rejeições na recolha analisada
Deteção de duplicados	6.009 únicos; 0 duplicados	Sem duplicados segundo a configuração usada
Correspondência GEO	6.009 associados; 0 sem correspondência	O catálogo cobriu as chaves processadas
Agrupamento	555 grupos gerados	Agregações por distrito, município, combustível e INE
Exportação CSV	555 grupos de dados	Resultado tabular disponível para outros sistemas

Verificação	Evidência observada	Interpretação
Exportação XML	555 elementos de dados	Mesmo volume da exportação CSV
Job principal	8 transformações com sucesso	Cadeia completa executada na ordem prevista
Node-RED	Tabela e gráfico visualizados	Resultados do CSV consumidos na apresentação

7.2. Resultados da implementação KNIME

O resultado final do KNIME é resultado_final.csv. As entradas observadas tinham aproximadamente 3.368 linhas (CSV) e 6.069 linhas (JSON). O Joiner CSV/JSON produziu 5.466 linhas, número mantido após a associação ao catálogo XML.

Estas contagens são específicas da execução documentada. Sem analisar o tipo de junção, as chaves e os registos não associados, não é possível interpretar as diferenças como uma taxa de qualidade ou de cobertura.

Tabela 10 — Resultado das etapas KNIME descritas no relatório original

Verificação	Resultado observado	Interpretação
Leitura e transformação do CSV	Preços convertidos para formato numérico; tratamento e filtragem executados.	Preparação para operações numéricas e integração.
Extração do JSON	Atributos e coordenadas extraídos para colunas.	Estrutura JSON convertida em dados tabulares.
Integração CSV + JSON	5 466 linhas na saída observada.	Resultado produzido pela configuração de junção utilizada.
Integração do XML	5 466 linhas na saída observada.	O catálogo foi associado sem alteração da contagem nessa execução.
Exportação e consulta	CSV aberto no Excel; filtros e ordenação testados.	Resultado utilizável para exploração tabular.

No Excel, o ficheiro permite filtrar os registos por combustível e município e ordenar os preços de forma crescente. Estas operações facilitam a identificação dos registos com preços mais baixos dentro do subconjunto selecionado. A utilidade do resultado depende, naturalmente, de os preços e as correspondências entre as fontes estarem corretos.

7.3. Leitura conjunta das duas abordagens

No Kettle, as 555 linhas finais são agregados estatísticos municipais; no KNIME, as 5.466 linhas são registos resultantes de junções. As contagens não são diretamente comparáveis, pois não está comprovada a equivalência das fontes, da data de recolha nem das regras de associação.

O Kettle permite consultar estatísticas em CSV, XML, HTTP e dashboard; o KNIME permite consultar a tabela final em CSV/Excel. Esta complementaridade resulta das abordagens adotadas ao mesmo problema, não de comunicação entre os programas.

8. Validação, comparação e limitações

8.1. Verificações realizadas

No Kettle, foram verificadas pré-visualizações, métricas de passos, ficheiros de saída, histórico do Job e consultas no Node-RED. Não há testes documentados com falhas de API, preços inválidos introduzidos propositadamente ou validação XSD.

No KNIME, está documentada a execução das junções, a exportação do CSV e a consulta no Excel. Falta validar uma amostra das correspondências e medir registos não associados, associações múltiplas e valores em falta em campos essenciais.

8.2. Comparação técnica das ferramentas

Tabela 11 — Comparação baseada nas operações efetivamente descritas

Critério	Kettle	KNIME
Estrutura	Oito transformações .ktr e um Job .kjb com ramificações.	Workflow visual com nós encadeados; Job autónomo não descrito.
Leitura das fontes	CSV por combustível e JSON via REST Client/GEO API PT.	CSV, JSON geográfico ArcGIS e XML de catálogo.
Tratamento	Limpeza de moeda e espaços, normalização territorial e códigos INE como texto.	Preço numérico, Missing Value, duplicados, marcas, JSON Path, XPath e coordenadas aproximadas.
Associação	União de dois combustíveis; Stream Lookup por distrito e município.	Joiner CSV/JSON por condições preparadas e Inner Join com catálogo XML.
Agregação	Sort Rows e Group By: média, mínimo, máximo e contagem.	Não foi documentada saída municipal agregada equivalente.
Exportação	CSV e XML de estatísticas; consumo posterior em Node-RED.	CSV final de registos integrados; consulta no Excel.
Execução/erros	Job com caminhos de sucesso/falha, histórico e Abort.	Nós e execução do workflow; sem fluxo autónomo de controlo de erros documentado.
Evolução	Ficheiros e caminhos parametrizáveis; testes de API/validação; visualização de preços.	Auditoria dos Joiner, validação espacial e integração posterior em base de dados.

No Kettle, a divisão em transformações e Job facilita a localização de falhas, mas gera dependências de ficheiros e caminhos locais. No KNIME, a sequência de nós permite acompanhar a preparação das fontes; para manutenção e reprodução, é necessário

documentar as duas colunas removidas no Missing Value e o tipo de junção. Não existe evidência para declarar uma das ferramentas globalmente superior.

8.3. Limitações e riscos

8.3.1. Limitações da implementação Kettle

A reprodução do dashboard depende da instalação do Node-RED e do pacote FlowFuse Dashboard 2.0. Os nós Read File utilizam caminhos absolutos, pelo que terão de ser ajustados noutra máquina.

O gráfico depende da seleção de linhas na tabela e apresenta número de observações, não preços. A pesquisa distingue certas variações de acentuação; a fonte de preços também não é atualizada automaticamente.

Zero rejeições na execução Kettle significa apenas que os registos analisados cumpriram as regras configuradas; não foram documentados testes intencionais com dados inválidos ou falhas de API. Os códigos INE identificam municípios, não postos individuais.

8.3.2. Limitações da implementação KNIME

Uma das dificuldades técnicas consistiu em transformar a estrutura hierárquica do JSON em linhas tabulares e extrair os atributos pretendidos. A utilização de JSON Path e da expansão de listas permitiu obter os campos necessários para a integração.

A leitura do XML também exigiu atenção à estrutura do documento e à forma como os elementos eram apresentados pelo nó de leitura. A extração por XPath permitiu separar o código, o nome e a unidade em colunas e criar uma tabela de referência adequada à junção.

Outra limitação está relacionada com a correspondência geográfica. O arredondamento das coordenadas facilita a comparação quando existem diferenças pequenas de precisão, mas não garante que duas coordenadas aproximadas identifiquem o mesmo posto. Um critério baseado apenas em coordenadas arredondadas pode associar locais próximos que são, na realidade, diferentes. A utilização conjunta de outras chaves e a validação de amostras são, por isso, importantes.

A integração depende ainda da qualidade, atualidade e consistência das fontes. Alterações na estrutura do serviço JSON, nos nomes dos combustíveis ou no formato do CSV podem exigir ajustes no workflow. A contagem de linhas de saída, isoladamente, não permite determinar a taxa de correspondência nem a ausência de erros.

Foi também testada uma consulta à API GEO API PT com um conjunto fixo de coordenadas, tendo sido obtida uma resposta HTTP 200 e extraídos campos como distrito, concelho, freguesia e altitude. Como a consulta foi realizada para coordenadas fixas e não foi integrada como enriquecimento de todos os registos da tabela final, esta experiência não é considerada uma funcionalidade completa do resultado final. Poderá servir de base a uma evolução futura.

Por fim, a exportação para CSV é adequada para consulta e partilha, mas não oferece por si só atualização automática, controlo transacional ou gestão de histórico. Estas capacidades exigiriam componentes adicionais.

8.3.3. Reprodutibilidade e risco de comparação indevida

Não foi demonstrado que Kettle e KNIME utilizem os mesmos ficheiros ou datas de recolha. No KNIME, os três critérios do Joiner CSV/JSON são visíveis, mas o tipo de junção e a auditoria das correspondências permanecem por documentar. Assim, os volumes finais não podem ser comparados como se representassem a mesma saída.

9. Vídeo de demonstração e repositórios

O vídeo exigido pelo enunciado deve demonstrar os dois workflows e os respetivos resultados: no Kettle, a execução do Job, CSV/XML e Node-RED; no KNIME, as entradas CSV/JSON/XML, os Joiner, o CSV Writer e resultado_final.csv.

Na apresentação e defesa, cada elemento deve explicar a implementação que realizou e mostrar os principais resultados e verificações.



Figuras 29 e 30 — QR Codes das demonstrações: KNIME (à esquerda) e Pentaho Kettle / Node-RED (à direita).

Vídeo KNIME: https://qrto.org/lHya9e | Vídeo Pentaho / Node-RED: https://youtu.be/Os4p-xmINcE

Repositório Pentaho Kettle / Node-RED: https://github.com/franciscoc20/ISI-TP01-Comparador-Combustiveis

10. Conclusão e trabalhos futuros

10.1. Conclusão

O trabalho documenta duas implementações ETL distintas para integrar preços de combustíveis em Portugal. No Kettle, oito transformações executadas por um Job produzem 555 agregados a partir de 6.009 observações validadas, com exportações CSV/XML e consulta em Node-RED.

No KNIME, a preparação e junção de CSV, JSON e XML produz uma tabela de 5.466 linhas, exportada para CSV e consultada no Excel. As saídas foram obtidas por regras e fontes diferentes e não devem ser tratadas como equivalentes.

As implementações demonstram leitura, limpeza, associação e exportação de dados heterogéneos. A limitação principal está na validação individual das correspondências do KNIME, no tipo de junção CSV/JSON e na proveniência temporal das fontes.

10.2. Trabalho futuro

Como melhorias futuras, recomenda-se parametrizar caminhos e fontes, registar datas de recolha e logs de execução e testar erros de API e dados inválidos. No Kettle, a interface poderá incluir análise de preços médios em vez de apenas contagens.

A criação de uma base de dados permitiria guardar histórico de preços e pesquisar postos, mas não está implementada no trabalho atual.

No KNIME, seria prioritário auditar os Joiner, contabilizar associações múltiplas e ausentes, melhorar critérios de proximidade geográfica e documentar as regras de tratamento de valores em falta. Atualização periódica e dashboard constituem trabalho futuro.

11. Referências bibliográficas

Ferreira, L., & Ribeiro, Ó. (2026). Integração de Sistemas de Informação — Trabalho Prático I. Enunciado da unidade curricular, ano letivo 2026/2027, UPCA..

Direção-Geral de Energia e Geologia. (s.d.). Preços dos Combustíveis Online. https://precoscombustiveis.dgeg.gov.pt/ (consultado em outubro de 2026).

Pentaho. (s.d.). Documentação do Pentaho Data Integration. https://docs.pentaho.com/

GEO API PT. (s.d.). Documentação do serviço de informação administrativa. https://json.geoapi.pt/ e https://geoapi.pt/docs/

Node-RED. (s.d.). Documentação técnica. https://nodered.org/docs/

FlowFuse. (s.d.). Node-RED Dashboard 2.0 — Documentação. https://dashboard.flowfuse.com/

KNIME. (s.d.). KNIME Analytics Platform Documentation. https://docs.knime.com/

Esri. (s.d.). ArcGIS REST Services — Layer (Feature Service). https://developers.arcgis.com/rest/services-reference/enterprise/layer-feature-service/

Direção-Geral de Energia e Geologia. (s.d.). Serviço ArcGIS PACVR/FeatureServer/0 — Postos de abastecimento. https://servergeo.dgeg.gov.pt/arcgis/rest/services/PACVR/FeatureServer/0.

World Wide Web Consortium. (2008). Extensible Markup Language (XML) 1.0 (Fifth Edition). https://www.w3.org/TR/xml/

Ecma International. (2017). ECMA-404 — The JSON Data Interchange Syntax. https://www.ecma-international.org/publications-and-standards/standards/ecma-404/

Anexos

Anexo A — Inventário de artefactos do projeto

Tabela 12 — Conjunto de artefactos descritos nos relatórios

Origem	Ficheiros / componentes	Função documentada
Kettle	.ktr: 01_gasoleo_simples; 03_gasolina_95_simples; 04_integrar_combustiveis; 05_validar_combustiveis	Importação, preparação e validação de preços.
Kettle	.ktr: 06_identificar_duplicados; 07_geoapi_municipios; 08_cruzar_combustiveis_municipios; 09_estatisticas_combustiveis	Deduplicação, referência municipal, Stream Lookup e agregação.
Kettle	10_job_principal_etl.kjb; ficheiros CSV tratados/intermédios	Sequência de processamento e resultados de verificação.
Kettle / Node-RED	estatisticas_combustiveis.csv; estatísticas XML; fluxo Node-RED	Saídas finais e interface/endpoint que lê o CSV.
KNIME	Workflow; ficheiros de entrada CSV, JSON e catálogo XML	Leitura, transformação e integração de formatos diferentes.
KNIME	resultado_final.csv	Tabela exportada para consulta no Excel.

Anexo B — Campos e significado das saídas

Tabela 13 — Semântica dos oito campos da exportação estatística Kettle

Kettle — campo	Significado documentado
Distrito	Distrito associado ao município da observação.
Municipio	Município a que pertence o grupo estatístico.
Combustivel	Gasolina simples 95 ou Gasóleo simples.
Codigo_INE	Identificador municipal conservado como texto, incluindo zeros iniciais.
Preco_Medio	Preço médio das observações do grupo, em €/L.
Preco_Minimo	Menor preço observado no grupo, em €/L.
Preco_Maximo	Maior preço observado no grupo, em €/L.
Numero_Registos	Número de linhas agregadas; não necessariamente postos distintos.

No KNIME, a saída contém os campos selecionados no Column Filter após os Joiner. Os relatórios confirmam a presença de informação de postos, localização, preços, combustíveis e campos de código/unidade do catálogo, mas não apresentam uma listagem final completa que permita fixar aqui um esquema exato sem consultar o workflow executável.